

TDE02 - Séries Temporais Redes Neurais Recorrentes

RNN - Recurrent Neural Networks

Modelo

No TDE02 usaremos as redes neurais recorrentes para fazer a previsão de dados de desempenho utilizando redes neurais recorrentes com o seguinte mdelo:

- Primeira camada: `Lambda` (formata a entrada para a segunda camada)
- Segunda e terceira camadas: `simpleRNN`
- Quarta camada: `Dense`
- Quarta camada: `Lambda` (formata a saída da rede)
- Função perda de `Huber` (treinamento)

Importar bibliotecas

```
import pandas as pd
import tensorflow as tf
import numpy as np
import matplotlib.pyplot as plt
```

Conectar com google Drive

Funções

Cálcular de métricas de previsão

```
# Métricas de previsão
def metricas(previsto, observado):
    erro = previsto - observado
    me = np.mean(erro)
    mse = np.square(erro).mean()
    rmse = np.sqrt(mse)
    mae = np.abs(erro).mean()
    mpe = (erro / observado).mean()
    mape = np.abs(erro / observado).mean()
    mins = np.amin(np.hstack([previsto[:,None],
                              observado[:,None]]), axis=1)
    maxs = np.amax(np.hstack([previsto[:,None],
                              observado[:,None]]), axis=1)
    minmax = 1 - np.mean(mins/maxs)
    return({'ME':me, 'MSE':mse, 'RMSE':rmse,
            # erro
            # ME
            # MSE
            # RMSE
            # MAE
            # MPE
            # MAPE
            # MINMAX
```

```
'MAE': mae, 'MPE': mpe, 'MAPE': mape,  
'MIN-MAX': minmax})
```

Plotar séries

```
### Plotar séries temporais  
def plotar_series(tempo, series, format="-", inicio=0, fim=None):  
  
    # Dimensões da figura  
    plt.figure(figsize=(10, 6))  
  
    if type(series) is tuple:  
        for series_num in series:  
            # Plotar valores x tempo  
            plt.plot(tempo[inicio:fim], series_num[inicio:fim],  
format)  
    else:  
        # Plotar valores x tempo  
        plt.plot(tempo[inicio:fim], series[inicio:fim], format)  
  
    # Rótulo do eixo x  
    plt.xlabel("Tempo")  
  
    # Rótulo do eixo y  
    plt.ylabel("Valor")  
  
    # Plotar grid  
    plt.grid(True)  
  
    # Mostrar a gráfico  
    plt.show()
```

Função para janelamento e lotes

```
def janelamento_lotes(serie, tam_janela, tam_lote,  
buffer_embaralhamento):  
    # Cria um dataset TF Dataset a partir dos valores da serie  
    dataset = tf.data.Dataset.from_tensor_slices(serie)  
  
    # Janelamento dos dados  
    dataset = dataset.window(tam_janela + 1, shift=1,  
drop_remainder=True)  
  
    # Ajustar as janelas (flatten) colocando seus elementos em lotes  
    dataset = dataset.flat_map(lambda window: window.batch(tam_janela  
+ 1))  
  
    # Criar tuplas com variáveis (features) e rótulos (labels)  
    dataset = dataset.map(lambda window: (window[:-1], window[-1]))
```

```

# Embaralhar janelas
dataset = dataset.shuffle(buffer_embaralhamento)

# Criar lotes de treinamento
dataset = dataset.batch(tam_lote).prefetch(1)

return dataset

```


Preparar dados

- Carregar os valores da série temporal do arquivo **serie_sintetica_D.csv**
- Gerar os valores de tempo
- Plotar a série

```

# Ler os dados
serie = np.loadtxt("/content/serie_sintetica_D.csv", delimiter=",",
dtype="float32")
# Criar array com o tempo
tempo = np.arange(len(serie), dtype="float32")
# Plotar série
plotar_series(tempo, serie)

```



Dividir os dados

```

# Definir o tamanho do conjunto de treinamento
tam_trein = 1000

```

```
# Conjunto de treinamento
tempo_trein = tempo[:tam_trein]
x_trein = serie[:tam_trein]

# Conjunto de validação
tempo_valid = tempo[tam_trein:]
x_valid = serie[tam_trein:]
```

Preparar dataset para treinamento

Parâmetros

```
# Parameters
tam_janela = 20
tam_lote = 32
tam_buffer_embaralhamento = 1000
```

Criar o dataset

```
# Criar o dataset de treinamento
dataset = janelamento_lotes(x_trein, tam_janela, tam_lote,
                             tam_buffer_embaralhamento)
```

Imprimir formato de variáveis (features) e rótulos (labels)

```
# Imprimir formato de variáveis e rótulos
for janela in dataset.take(1):
    print(f'Formato das variáveis: {janela[0].shape}')
    print(f'Formato dos rótulos: {janela[1].shape}')
```

```
Formato das variáveis: (32, 20)
Formato dos rótulos: (32,)
```

Construir o modelo

Modelo

Modelo sequencial composto por 5 camadas:

Primeira camada do tipo lambda função [Lambda](#). Transforma a entrada para um tensor tridimensional no formato [tamanho do lote, intervalos de tempo, features], conforme exigido pela camada SimpleRNN (ver [documentação](#)). A função [Lambda](#) remodela o formato do dataset de [tam_janela, tam_lote] para [tam_janela, tam_lote, 1], adicionando uma dimensão no último eixo da entrada. A quantidade de pontos de dados na janela (tam_janela) são mapeados para a mesma quantidade de intervalos de tempo da RNN ao definir o parâmetro `input_shape` igual ao tamanho da janela (tam_janela).

Segunda e a terceira camadas do tipo `SimpleRNN`. O primeiro argumento para camadas `SimpleRNN` é um inteiro positivo com a dimensionalidade da saída, que deve ser múltiplo do tamanho da janela. A segunda camada deverá ter o argumento `return_sequences` definido como `True` para encaminhar sua saída de volta para a entrada da terceira camada.

Quarta camada do tipo densa (`Dense`).

Quinta camada do tipo função `Lambda`. Incluída para facilitar o treinamento. Configura a saída para valores próximos aos valores observados na série. Como as camadas `SimpleRNN` usam a função de ativação `tanh` que definem um intervalo de saída entre `[-1,1]` e os valores observados na série estão próximos de 100, a reformatação é usada uma camada `Lambda()` que multiplica o tamanho da saída por 100.

```
modelo_RNN = tf.keras.models.Sequential([
    tf.keras.layers.Lambda(lambda x: tf.expand_dims(x, axis=-1),
                           input_shape=[tam_janela]),
    tf.keras.layers.SimpleRNN(2*tam_janela, return_sequences=True),
    tf.keras.layers.SimpleRNN(2*tam_janela),
    tf.keras.layers.Dense(1),
    tf.keras.layers.Lambda(lambda x: x * 100.0)
])
```

```
# Imprimir sumário
modelo_RNN.summary()
```

```
/usr/local/lib/python3.10/dist-packages/keras/src/layers/core/
lambda_layer.py:65: UserWarning: Do not pass an
`input_shape`/`input_dim` argument to a layer. When using Sequential
models, prefer using an `Input(shape)` object as the first layer in
the model instead.
```

```
super().__init__(**kwargs)
```

```
Model: "sequential"
```

Layer (type)	Output Shape
Param #	
lambda (Lambda)	(None, 20, 1)
0	
simple_rnn (SimpleRNN)	(None, 20, 40)
1,680	
simple_rnn_1 (SimpleRNN)	(None, 40)
3,240	

	dense (Dense)	(None, 1)
41		
	lambda_1 (Lambda)	(None, 1)
0		
Total params: 4,961 (19.38 KB)		
Trainable params: 4,961 (19.38 KB)		
Non-trainable params: 0 (0.00 B)		

Ajustar a taxa de aprendizagem

Treinar o modelo para ajuste de taxa de aprendizagem

Definir parâmetros:

- Função LearningRateScheduler para ajuste no callback
- Algoritmo de otimização: SGD
- Função de perda: [Huber](#) para minimizar a sensibilidade a outliers.

Treinar o modelo

```
# Função de callback para escalonamento de taxa de aprendizagem
lr_schedule = tf.keras.callbacks.LearningRateScheduler(
    lambda epoch: 1e-8 * 10**(epoch / 20))

# Definir algoritmo de otimização
otimizador = tf.keras.optimizers.SGD(momentum=0.9)

# Definir função de perda
modelo_RNN.compile(loss=tf.keras.losses.Huber(),
optimizer=otimizador)

# Treinar o modelo
resultado_treinamento = modelo_RNN.fit(dataset, epochs=100,
callbacks=[lr_schedule])
```

```
Epoch 1/100
31/31 ————— 3s 10ms/step - loss: 20.5146 -
learning_rate: 1.0000e-08
Epoch 2/100
```

```
/usr/lib/python3.10/contextlib.py:153: UserWarning: Your input ran out
of data; interrupting training. Make sure that your dataset or
```

generator can generate at least `steps_per_epoch * epochs` batches. You may need to use the `.repeat()` function when building your dataset.

```
self.gen.throw(typ, value, traceback)
```

```
31/31 _____ 1s 10ms/step - loss: 18.5910 -  
learning_rate: 1.1220e-08  
Epoch 3/100  
31/31 _____ 0s 9ms/step - loss: 17.5031 -  
learning_rate: 1.2589e-08  
Epoch 4/100  
31/31 _____ 0s 10ms/step - loss: 18.0856 -  
learning_rate: 1.4125e-08  
Epoch 5/100  
31/31 _____ 1s 10ms/step - loss: 18.3818 -  
learning_rate: 1.5849e-08  
Epoch 6/100  
31/31 _____ 1s 10ms/step - loss: 18.6415 -  
learning_rate: 1.7783e-08  
Epoch 7/100  
31/31 _____ 0s 11ms/step - loss: 17.4237 -  
learning_rate: 1.9953e-08  
Epoch 8/100  
31/31 _____ 0s 10ms/step - loss: 16.7274 -  
learning_rate: 2.2387e-08  
Epoch 9/100  
31/31 _____ 1s 10ms/step - loss: 17.0898 -  
learning_rate: 2.5119e-08  
Epoch 10/100  
31/31 _____ 1s 15ms/step - loss: 16.9835 -  
learning_rate: 2.8184e-08  
Epoch 11/100  
31/31 _____ 1s 18ms/step - loss: 17.0992 -  
learning_rate: 3.1623e-08  
Epoch 12/100  
31/31 _____ 1s 11ms/step - loss: 16.6900 -  
learning_rate: 3.5481e-08  
Epoch 13/100  
31/31 _____ 1s 10ms/step - loss: 16.6142 -  
learning_rate: 3.9811e-08  
Epoch 14/100  
31/31 _____ 0s 11ms/step - loss: 16.7250 -  
learning_rate: 4.4668e-08  
Epoch 15/100  
31/31 _____ 1s 10ms/step - loss: 15.4876 -  
learning_rate: 5.0119e-08  
Epoch 16/100  
31/31 _____ 1s 9ms/step - loss: 15.6782 -  
learning_rate: 5.6234e-08  
Epoch 17/100
```

```
31/31 _____ 1s 9ms/step - loss: 15.5584 -  
learning_rate: 6.3096e-08  
Epoch 18/100  
31/31 _____ 1s 10ms/step - loss: 14.9415 -  
learning_rate: 7.0795e-08  
Epoch 19/100  
31/31 _____ 1s 10ms/step - loss: 14.7870 -  
learning_rate: 7.9433e-08  
Epoch 20/100  
31/31 _____ 0s 11ms/step - loss: 14.3104 -  
learning_rate: 8.9125e-08  
Epoch 21/100  
31/31 _____ 0s 11ms/step - loss: 14.1978 -  
learning_rate: 1.0000e-07  
Epoch 22/100  
31/31 _____ 1s 10ms/step - loss: 13.7860 -  
learning_rate: 1.1220e-07  
Epoch 23/100  
31/31 _____ 1s 12ms/step - loss: 13.4100 -  
learning_rate: 1.2589e-07  
Epoch 24/100  
31/31 _____ 0s 10ms/step - loss: 13.5280 -  
learning_rate: 1.4125e-07  
Epoch 25/100  
31/31 _____ 1s 11ms/step - loss: 13.6873 -  
learning_rate: 1.5849e-07  
Epoch 26/100  
31/31 _____ 1s 10ms/step - loss: 12.9754 -  
learning_rate: 1.7783e-07  
Epoch 27/100  
31/31 _____ 1s 10ms/step - loss: 12.7676 -  
learning_rate: 1.9953e-07  
Epoch 28/100  
31/31 _____ 1s 12ms/step - loss: 12.8392 -  
learning_rate: 2.2387e-07  
Epoch 29/100  
31/31 _____ 1s 18ms/step - loss: 11.1665 -  
learning_rate: 2.5119e-07  
Epoch 30/100  
31/31 _____ 1s 18ms/step - loss: 12.0939 -  
learning_rate: 2.8184e-07  
Epoch 31/100  
31/31 _____ 1s 12ms/step - loss: 12.1196 -  
learning_rate: 3.1623e-07  
Epoch 32/100  
31/31 _____ 0s 10ms/step - loss: 11.2174 -  
learning_rate: 3.5481e-07  
Epoch 33/100  
31/31 _____ 1s 12ms/step - loss: 10.7991 -
```



```
learning_rate: 3.9811e-07
Epoch 34/100
31/31 _____ 0s 10ms/step - loss: 11.6812 -
learning_rate: 4.4668e-07
Epoch 35/100
31/31 _____ 1s 10ms/step - loss: 11.8122 -
learning_rate: 5.0119e-07
Epoch 36/100
31/31 _____ 0s 11ms/step - loss: 10.8729 -
learning_rate: 5.6234e-07
Epoch 37/100
31/31 _____ 1s 11ms/step - loss: 11.5444 -
learning_rate: 6.3096e-07
Epoch 38/100
31/31 _____ 1s 12ms/step - loss: 10.9216 -
learning_rate: 7.0795e-07
Epoch 39/100
31/31 _____ 1s 9ms/step - loss: 10.2995 -
learning_rate: 7.9433e-07
Epoch 40/100
31/31 _____ 0s 10ms/step - loss: 10.6656 -
learning_rate: 8.9125e-07
Epoch 41/100
31/31 _____ 1s 28ms/step - loss: 11.7357 -
learning_rate: 1.0000e-06
Epoch 42/100
31/31 _____ 1s 11ms/step - loss: 10.8912 -
learning_rate: 1.1220e-06
Epoch 43/100
31/31 _____ 0s 9ms/step - loss: 12.3886 -
learning_rate: 1.2589e-06
Epoch 44/100
31/31 _____ 0s 9ms/step - loss: 10.2559 -
learning_rate: 1.4125e-06
Epoch 45/100
31/31 _____ 1s 10ms/step - loss: 11.2771 -
learning_rate: 1.5849e-06
Epoch 46/100
31/31 _____ 1s 10ms/step - loss: 11.1895 -
learning_rate: 1.7783e-06
Epoch 47/100
31/31 _____ 0s 10ms/step - loss: 10.2717 -
learning_rate: 1.9953e-06
Epoch 48/100
31/31 _____ 1s 14ms/step - loss: 11.5808 -
learning_rate: 2.2387e-06
Epoch 49/100
31/31 _____ 1s 16ms/step - loss: 11.0075 -
learning_rate: 2.5119e-06
```

```
Epoch 50/100
31/31 _____ 1s 15ms/step - loss: 10.0990 -
learning_rate: 2.8184e-06
Epoch 51/100
31/31 _____ 1s 11ms/step - loss: 10.6549 -
learning_rate: 3.1623e-06
Epoch 52/100
31/31 _____ 0s 10ms/step - loss: 9.6731 -
learning_rate: 3.5481e-06
Epoch 53/100
31/31 _____ 1s 12ms/step - loss: 10.2547 -
learning_rate: 3.9811e-06
Epoch 54/100
31/31 _____ 0s 10ms/step - loss: 9.4757 -
learning_rate: 4.4668e-06
Epoch 55/100
31/31 _____ 0s 12ms/step - loss: 16.6387 -
learning_rate: 5.0119e-06
Epoch 56/100
31/31 _____ 0s 11ms/step - loss: 11.1754 -
learning_rate: 5.6234e-06
Epoch 57/100
31/31 _____ 1s 13ms/step - loss: 9.0353 -
learning_rate: 6.3096e-06
Epoch 58/100
31/31 _____ 1s 11ms/step - loss: 10.5498 -
learning_rate: 7.0795e-06
Epoch 59/100
31/31 _____ 1s 10ms/step - loss: 10.0655 -
learning_rate: 7.9433e-06
Epoch 60/100
31/31 _____ 0s 11ms/step - loss: 12.4224 -
learning_rate: 8.9125e-06
Epoch 61/100
31/31 _____ 1s 10ms/step - loss: 9.6848 -
learning_rate: 1.0000e-05
Epoch 62/100
31/31 _____ 0s 10ms/step - loss: 13.8264 -
learning_rate: 1.1220e-05
Epoch 63/100
31/31 _____ 1s 10ms/step - loss: 10.6117 -
learning_rate: 1.2589e-05
Epoch 64/100
31/31 _____ 1s 11ms/step - loss: 18.6919 -
learning_rate: 1.4125e-05
Epoch 65/100
31/31 _____ 1s 10ms/step - loss: 15.5350 -
learning_rate: 1.5849e-05
Epoch 66/100
```

```
31/31 _____ 0s 11ms/step - loss: 13.7956 -  
learning_rate: 1.7783e-05  
Epoch 67/100  
31/31 _____ 0s 10ms/step - loss: 13.9408 -  
learning_rate: 1.9953e-05  
Epoch 68/100  
31/31 _____ 1s 11ms/step - loss: 14.8531 -  
learning_rate: 2.2387e-05  
Epoch 69/100  
31/31 _____ 1s 15ms/step - loss: 15.0892 -  
learning_rate: 2.5119e-05  
Epoch 70/100  
31/31 _____ 1s 17ms/step - loss: 12.0099 -  
learning_rate: 2.8184e-05  
Epoch 71/100  
31/31 _____ 1s 19ms/step - loss: 16.7686 -  
learning_rate: 3.1623e-05  
Epoch 72/100  
31/31 _____ 1s 10ms/step - loss: 13.4157 -  
learning_rate: 3.5481e-05  
Epoch 73/100  
31/31 _____ 0s 9ms/step - loss: 20.7957 -  
learning_rate: 3.9811e-05  
Epoch 74/100  
31/31 _____ 0s 10ms/step - loss: 15.8446 -  
learning_rate: 4.4668e-05  
Epoch 75/100  
31/31 _____ 1s 9ms/step - loss: 17.2856 -  
learning_rate: 5.0119e-05  
Epoch 76/100  
31/31 _____ 1s 12ms/step - loss: 18.1880 -  
learning_rate: 5.6234e-05  
Epoch 77/100  
31/31 _____ 1s 10ms/step - loss: 22.9493 -  
learning_rate: 6.3096e-05  
Epoch 78/100  
31/31 _____ 0s 12ms/step - loss: 22.5715 -  
learning_rate: 7.0795e-05  
Epoch 79/100  
31/31 _____ 1s 10ms/step - loss: 21.7857 -  
learning_rate: 7.9433e-05  
Epoch 80/100  
31/31 _____ 0s 12ms/step - loss: 23.3585 -  
learning_rate: 8.9125e-05  
Epoch 81/100  
31/31 _____ 1s 10ms/step - loss: 19.5045 -  
learning_rate: 1.0000e-04  
Epoch 82/100  
31/31 _____ 1s 11ms/step - loss: 22.6758 -
```

```
learning_rate: 1.1220e-04
Epoch 83/100
31/31 _____ 1s 12ms/step - loss: 23.2631 -
learning_rate: 1.2589e-04
Epoch 84/100
31/31 _____ 1s 10ms/step - loss: 24.3410 -
learning_rate: 1.4125e-04
Epoch 85/100
31/31 _____ 1s 9ms/step - loss: 23.2483 -
learning_rate: 1.5849e-04
Epoch 86/100
31/31 _____ 0s 10ms/step - loss: 23.8898 -
learning_rate: 1.7783e-04
Epoch 87/100
31/31 _____ 1s 11ms/step - loss: 22.3567 -
learning_rate: 1.9953e-04
Epoch 88/100
31/31 _____ 1s 12ms/step - loss: 25.4452 -
learning_rate: 2.2387e-04
Epoch 89/100
31/31 _____ 1s 15ms/step - loss: 28.4218 -
learning_rate: 2.5119e-04
Epoch 90/100
31/31 _____ 1s 18ms/step - loss: 24.3553 -
learning_rate: 2.8184e-04
Epoch 91/100
31/31 _____ 1s 17ms/step - loss: 27.4770 -
learning_rate: 3.1623e-04
Epoch 92/100
31/31 _____ 1s 10ms/step - loss: 23.3223 -
learning_rate: 3.5481e-04
Epoch 93/100
31/31 _____ 1s 11ms/step - loss: 22.3032 -
learning_rate: 3.9811e-04
Epoch 94/100
31/31 _____ 0s 11ms/step - loss: 25.5876 -
learning_rate: 4.4668e-04
Epoch 95/100
31/31 _____ 0s 10ms/step - loss: 22.1305 -
learning_rate: 5.0119e-04
Epoch 96/100
31/31 _____ 1s 11ms/step - loss: 25.5256 -
learning_rate: 5.6234e-04
Epoch 97/100
31/31 _____ 0s 9ms/step - loss: 25.8699 -
learning_rate: 6.3096e-04
Epoch 98/100
31/31 _____ 0s 10ms/step - loss: 26.5455 -
learning_rate: 7.0795e-04
```

```
Epoch 99/100
31/31 _____ 1s 10ms/step - loss: 26.5924 -
learning_rate: 7.9433e-04
Epoch 100/100
31/31 _____ 1s 11ms/step - loss: 27.7154 -
learning_rate: 8.9125e-04
```

Visualizar perdas para selecionar taxa de aprendizagem

Plotar perda em função da taxa de aprendizagem

```
# Definir o array de taxas de aprendizagem
taxas_aprendizagem = 1e-8 * (10 ** (np.arange(100) / 20))

# Definir tamanho da figura
plt.figure(figsize=(10, 6))


# Definir grid
plt.grid(True)

# Plotar perda em escala logarítmica
plt.semilogx(taxas_aprendizagem,
             resultado_treinamento.history["loss"])

# Aumentar tamanho das marcas de ticks
plt.tick_params('both', length=10, width=1, which='both')

# Definir limites de plotagem
plt.axis([1e-8, 1e-3, 0, 50])

(1e-08, 0.001, 0.0, 50.0)
```



Alterar os limites do gráfico (zoom in)

Observar onde o gráfico se torna instável.

```
# Tamanho da figura
plt.figure(figsize=(10, 6))


# Definir grid
plt.grid(True)

# Plotar perda em escala logarítmica
plt.semilogx(taxas_aprendizagem,
             resultado_treinamento.history["loss"])

# Aumentar tamanho das marcas de ticks
plt.tick_params('both', length=10, width=1, which='both')

# Definir limites de plotagem
plt.axis([1e-8, 1e-4, 0, 60])

(1e-08, 0.0001, 0.0, 60.0)
```



Construir o modelo

```
# Construir modelo RNN
modelo_RNN = tf.keras.models.Sequential([
    tf.keras.layers.Lambda(lambda x: tf.expand_dims(x, axis=-1),
                           input_shape=[tam_janela]),
    tf.keras.layers.SimpleRNN(2*tam_janela, return_sequences=True),
    tf.keras.layers.SimpleRNN(2*tam_janela),
    tf.keras.layers.Dense(1),
    tf.keras.layers.Lambda(lambda x: x * 100.0)
])
```

Treinar o modelo

Usar a taxa de aprendizagem $1e-6$ (pode testar com outros valores).

```
# Definir taxa de aprendizagem
taxa_de_aprendizagem = 1e-6
# taxa_de_aprendizagem = 1e-7

# Definir algoritmo de otimização
otimizador =
tf.keras.optimizers.SGD(learning_rate=taxa_de_aprendizagem,
momentum=0.9)

# Definir parâmetros
```

```
modelo_RNN.compile(loss=tf.keras.losses.Huber(),
                    optimizer=otimizador,
                    metrics=["mae"])
```

```
# Treinar o modelo
```

```
resultado_treinamento_RNN = modelo_RNN.fit(dataset, epochs=100)
```

```
Epoch 1/100
31/31 _____ 3s 10ms/step - loss: 23.1926 - mae: 23.6882
Epoch 2/100
31/31 _____ 1s 10ms/step - loss: 17.3315 - mae: 17.8253
Epoch 3/100
31/31 _____ 1s 17ms/step - loss: 16.2537 - mae: 16.7486
Epoch 4/100
31/31 _____ 1s 20ms/step - loss: 15.7438 - mae: 16.2378
Epoch 5/100
31/31 _____ 1s 12ms/step - loss: 13.9522 - mae: 14.4456
Epoch 6/100
31/31 _____ 0s 10ms/step - loss: 13.5374 - mae: 14.0317
Epoch 7/100
31/31 _____ 0s 12ms/step - loss: 12.7374 - mae: 13.2316
Epoch 8/100
31/31 _____ 0s 9ms/step - loss: 11.9055 - mae: 12.3939
Epoch 9/100
31/31 _____ 0s 10ms/step - loss: 11.2650 - mae: 11.7557
Epoch 10/100
31/31 _____ 1s 10ms/step - loss: 11.2251 - mae: 11.7144
Epoch 11/100
31/31 _____ 0s 10ms/step - loss: 10.0258 - mae: 10.5121
Epoch 12/100
31/31 _____ 1s 9ms/step - loss: 9.5520 - mae: 10.0392
Epoch 13/100
31/31 _____ 1s 10ms/step - loss: 9.6412 - mae: 10.1291
Epoch 14/100
31/31 _____ 1s 20ms/step - loss: 9.2726 - mae: 9.7608
Epoch 15/100
31/31 _____ 1s 25ms/step - loss: 9.3874 - mae: 9.8730
Epoch 16/100
31/31 _____ 1s 11ms/step - loss: 9.4785 - mae: 9.9649
Epoch 17/100
31/31 _____ 0s 10ms/step - loss: 9.1791 - mae: 9.6636
Epoch 18/100
31/31 _____ 0s 12ms/step - loss: 10.1642 - mae: 10.6559
Epoch 19/100
31/31 _____ 0s 9ms/step - loss: 9.2424 - mae: 9.7298
Epoch 20/100
31/31 _____ 1s 10ms/step - loss: 9.2997 - mae: 9.7828
Epoch 21/100
31/31 _____ 0s 9ms/step - loss: 9.1802 - mae: 9.6652
Epoch 22/100
```


31/31	_____	1s	15ms/step	-	loss: 8.9598	-	mae: 9.4470
Epoch 23/100							
31/31	_____	1s	18ms/step	-	loss: 9.0067	-	mae: 9.4943
Epoch 24/100							
31/31	_____	1s	11ms/step	-	loss: 8.6963	-	mae: 9.1830
Epoch 25/100							
31/31	_____	1s	10ms/step	-	loss: 9.4800	-	mae: 9.9648
Epoch 26/100							
31/31	_____	0s	11ms/step	-	loss: 9.6580	-	mae: 10.1465
Epoch 27/100							
31/31	_____	1s	10ms/step	-	loss: 8.4966	-	mae: 8.9843
Epoch 28/100							
31/31	_____	1s	11ms/step	-	loss: 8.8624	-	mae: 9.3537
Epoch 29/100							
31/31	_____	1s	11ms/step	-	loss: 8.7135	-	mae: 9.1973
Epoch 30/100							
31/31	_____	1s	11ms/step	-	loss: 9.0215	-	mae: 9.5142
Epoch 31/100							
31/31	_____	0s	11ms/step	-	loss: 8.5199	-	mae: 9.0089
Epoch 32/100							
31/31	_____	1s	10ms/step	-	loss: 9.5104	-	mae: 10.0021
Epoch 33/100							
31/31	_____	1s	9ms/step	-	loss: 9.4572	-	mae: 9.9442
Epoch 34/100							
31/31	_____	0s	9ms/step	-	loss: 9.1335	-	mae: 9.6225
Epoch 35/100							
31/31	_____	1s	12ms/step	-	loss: 8.8147	-	mae: 9.3029
Epoch 36/100							
31/31	_____	1s	10ms/step	-	loss: 9.0467	-	mae: 9.5332
Epoch 37/100							
31/31	_____	1s	10ms/step	-	loss: 8.7472	-	mae: 9.2372
Epoch 38/100							
31/31	_____	1s	10ms/step	-	loss: 9.1512	-	mae: 9.6373
Epoch 39/100							
31/31	_____	1s	9ms/step	-	loss: 8.8695	-	mae: 9.3594
Epoch 40/100							
31/31	_____	1s	11ms/step	-	loss: 8.8767	-	mae: 9.3635
Epoch 41/100							
31/31	_____	1s	19ms/step	-	loss: 8.7956	-	mae: 9.2838
Epoch 42/100							
31/31	_____	1s	18ms/step	-	loss: 8.8724	-	mae: 9.3602
Epoch 43/100							
31/31	_____	1s	20ms/step	-	loss: 8.5634	-	mae: 9.0512
Epoch 44/100							
31/31	_____	1s	11ms/step	-	loss: 8.6246	-	mae: 9.1082
Epoch 45/100							
31/31	_____	0s	11ms/step	-	loss: 8.5236	-	mae: 9.0112
Epoch 46/100							
31/31	_____	1s	11ms/step	-	loss: 8.7534	-	mae: 9.2401

Epoch 47/100			
31/31	1s 9ms/step	loss: 7.8875	mae: 8.3724
Epoch 48/100			
31/31	0s 12ms/step	loss: 8.9622	mae: 9.4534
Epoch 49/100			
31/31	0s 10ms/step	loss: 8.5391	mae: 9.0258
Epoch 50/100			
31/31	0s 12ms/step	loss: 8.4414	mae: 8.9292
Epoch 51/100			
31/31	1s 11ms/step	loss: 7.8235	mae: 8.3056
Epoch 52/100			
31/31	1s 12ms/step	loss: 8.2772	mae: 8.7610
Epoch 53/100			
31/31	0s 10ms/step	loss: 8.5267	mae: 9.0168
Epoch 54/100			
31/31	1s 10ms/step	loss: 8.4197	mae: 8.9050
Epoch 55/100			
31/31	0s 9ms/step	loss: 8.7124	mae: 9.1965
Epoch 56/100			
31/31	1s 11ms/step	loss: 8.5725	mae: 9.0585
Epoch 57/100			
31/31	0s 10ms/step	loss: 8.6811	mae: 9.1690
Epoch 58/100			
31/31	1s 11ms/step	loss: 8.5075	mae: 8.9959
Epoch 59/100			
31/31	0s 11ms/step	loss: 8.2983	mae: 8.7847
Epoch 60/100			
31/31	0s 11ms/step	loss: 8.6940	mae: 9.1816
Epoch 61/100			
31/31	0s 10ms/step	loss: 7.8754	mae: 8.3643
Epoch 62/100			
31/31	0s 11ms/step	loss: 7.7349	mae: 8.2181
Epoch 63/100			
31/31	1s 16ms/step	loss: 8.4891	mae: 8.9697
Epoch 64/100			
31/31	1s 18ms/step	loss: 8.4668	mae: 8.9522
Epoch 65/100			
31/31	1s 18ms/step	loss: 8.3536	mae: 8.8408
Epoch 66/100			
31/31	1s 13ms/step	loss: 8.0448	mae: 8.5267
Epoch 67/100			
31/31	0s 10ms/step	loss: 8.2099	mae: 8.6991
Epoch 68/100			
31/31	1s 12ms/step	loss: 8.4243	mae: 8.9090
Epoch 69/100			
31/31	1s 11ms/step	loss: 8.2717	mae: 8.7543
Epoch 70/100			
31/31	0s 11ms/step	loss: 8.3773	mae: 8.8627
Epoch 71/100			

31/31	_____	0s	11ms/step	-	loss: 7.8381	-	mae: 8.3215
Epoch 72/100							
31/31	_____	1s	10ms/step	-	loss: 8.4879	-	mae: 8.9711
Epoch 73/100							
31/31	_____	0s	11ms/step	-	loss: 8.3853	-	mae: 8.8692
Epoch 74/100							
31/31	_____	1s	10ms/step	-	loss: 7.7638	-	mae: 8.2492
Epoch 75/100							
31/31	_____	0s	10ms/step	-	loss: 7.9307	-	mae: 8.4135
Epoch 76/100							
31/31	_____	1s	10ms/step	-	loss: 8.2927	-	mae: 8.7765
Epoch 77/100							
31/31	_____	0s	12ms/step	-	loss: 7.9129	-	mae: 8.3995
Epoch 78/100							
31/31	_____	1s	11ms/step	-	loss: 7.7349	-	mae: 8.2190
Epoch 79/100							
31/31	_____	1s	10ms/step	-	loss: 8.2716	-	mae: 8.7544
Epoch 80/100							
31/31	_____	0s	9ms/step	-	loss: 8.3659	-	mae: 8.8530
Epoch 81/100							
31/31	_____	1s	10ms/step	-	loss: 8.1915	-	mae: 8.6778
Epoch 82/100							
31/31	_____	1s	11ms/step	-	loss: 8.3183	-	mae: 8.8022
Epoch 83/100							
31/31	_____	0s	10ms/step	-	loss: 7.9840	-	mae: 8.4719
Epoch 84/100							
31/31	_____	1s	16ms/step	-	loss: 7.3551	-	mae: 7.8360
Epoch 85/100							
31/31	_____	1s	18ms/step	-	loss: 7.9362	-	mae: 8.4173
Epoch 86/100							
31/31	_____	1s	10ms/step	-	loss: 8.2312	-	mae: 8.7188
Epoch 87/100							
31/31	_____	0s	10ms/step	-	loss: 7.9010	-	mae: 8.3863
Epoch 88/100							
31/31	_____	0s	11ms/step	-	loss: 8.4020	-	mae: 8.8904
Epoch 89/100							
31/31	_____	1s	12ms/step	-	loss: 8.4453	-	mae: 8.9326
Epoch 90/100							
31/31	_____	0s	10ms/step	-	loss: 7.7182	-	mae: 8.2002
Epoch 91/100							
31/31	_____	0s	12ms/step	-	loss: 8.0101	-	mae: 8.4956
Epoch 92/100							
31/31	_____	1s	10ms/step	-	loss: 8.2163	-	mae: 8.7012
Epoch 93/100							
31/31	_____	0s	10ms/step	-	loss: 8.0939	-	mae: 8.5794
Epoch 94/100							
31/31	_____	0s	10ms/step	-	loss: 8.1932	-	mae: 8.6803
Epoch 95/100							
31/31	_____	1s	12ms/step	-	loss: 8.3882	-	mae: 8.8762

```

Epoch 96/100
31/31 _____ 0s 10ms/step - loss: 7.9637 - mae: 8.4489
Epoch 97/100
31/31 _____ 0s 11ms/step - loss: 8.2900 - mae: 8.7715
Epoch 98/100
31/31 _____ 1s 9ms/step - loss: 8.8865 - mae: 9.3701
Epoch 99/100
31/31 _____ 1s 10ms/step - loss: 7.9113 - mae: 8.3912
Epoch 100/100
31/31 _____ 1s 11ms/step - loss: 8.3719 - mae: 8.8586

```

Previsão

O modelo é maior do que os utilizados anteriormente e a natureza sequencial das RNNs tornam as previsões mais lentas. Nas RNNs as entradas passam por uma série de etapas de tempo sequenciais, em vez do processamento paralelo.

```

# Inicializar lista de previsões
forecast = []

# Selecionar pontos que estão alinhados com o conjunto de validação
serie_valid = serie[tam_trein - tam_janela:]

# Usar o modelo para prever um valor para cada janela
for indice in range(len(serie_valid) - tam_janela):
    forecast.append(modelo_RNN.predict(serie_valid[indice:indice +
tam_janela][np.newaxis]))

# Converter para formato esperado pela função plotar_series
previsao = np.array(forecast).squeeze()

# Plotar as séries de validação e de previsão
plotar_series(tempo_valid, (x_valid, previsao))

1/1 _____ 0s 276ms/step
1/1 _____ 0s 24ms/step
1/1 _____ 0s 24ms/step
1/1 _____ 0s 27ms/step
1/1 _____ 0s 31ms/step
1/1 _____ 0s 30ms/step
1/1 _____ 0s 30ms/step
1/1 _____ 0s 24ms/step
1/1 _____ 0s 25ms/step
1/1 _____ 0s 26ms/step
1/1 _____ 0s 22ms/step
1/1 _____ 0s 20ms/step
1/1 _____ 0s 20ms/step
1/1 _____ 0s 21ms/step
1/1 _____ 0s 21ms/step

```

1/1	_____	0s	27ms/step
1/1	_____	0s	27ms/step
1/1	_____	0s	22ms/step
1/1	_____	0s	20ms/step
1/1	_____	0s	23ms/step
1/1	_____	0s	31ms/step
1/1	_____	0s	43ms/step
1/1	_____	0s	36ms/step
1/1	_____	0s	40ms/step
1/1	_____	0s	42ms/step
1/1	_____	0s	38ms/step
1/1	_____	0s	38ms/step
1/1	_____	0s	35ms/step
1/1	_____	0s	49ms/step
1/1	_____	0s	35ms/step
1/1	_____	0s	31ms/step
1/1	_____	0s	36ms/step
1/1	_____	0s	30ms/step
1/1	_____	0s	39ms/step
1/1	_____	0s	38ms/step
1/1	_____	0s	33ms/step
1/1	_____	0s	32ms/step
1/1	_____	0s	35ms/step
1/1	_____	0s	35ms/step
1/1	_____	0s	39ms/step
1/1	_____	0s	34ms/step
1/1	_____	0s	43ms/step
1/1	_____	0s	43ms/step
1/1	_____	0s	41ms/step
1/1	_____	0s	38ms/step
1/1	_____	0s	46ms/step
1/1	_____	0s	24ms/step
1/1	_____	0s	25ms/step
1/1	_____	0s	27ms/step
1/1	_____	0s	29ms/step
1/1	_____	0s	28ms/step
1/1	_____	0s	26ms/step
1/1	_____	0s	23ms/step
1/1	_____	0s	24ms/step
1/1	_____	0s	22ms/step
1/1	_____	0s	23ms/step
1/1	_____	0s	25ms/step
1/1	_____	0s	24ms/step
1/1	_____	0s	25ms/step
1/1	_____	0s	29ms/step
1/1	_____	0s	32ms/step
1/1	_____	0s	34ms/step
1/1	_____	0s	25ms/step
1/1	_____	0s	23ms/step

1/1	_____	0s	28ms/step
1/1	_____	0s	23ms/step
1/1	_____	0s	23ms/step
1/1	_____	0s	24ms/step
1/1	_____	0s	20ms/step
1/1	_____	0s	23ms/step
1/1	_____	0s	21ms/step
1/1	_____	0s	28ms/step
1/1	_____	0s	25ms/step
1/1	_____	0s	22ms/step
1/1	_____	0s	22ms/step
1/1	_____	0s	20ms/step
1/1	_____	0s	22ms/step
1/1	_____	0s	21ms/step
1/1	_____	0s	22ms/step
1/1	_____	0s	20ms/step
1/1	_____	0s	22ms/step
1/1	_____	0s	24ms/step
1/1	_____	0s	28ms/step
1/1	_____	0s	29ms/step
1/1	_____	0s	24ms/step
1/1	_____	0s	23ms/step
1/1	_____	0s	24ms/step
1/1	_____	0s	24ms/step
1/1	_____	0s	23ms/step
1/1	_____	0s	25ms/step
1/1	_____	0s	23ms/step
1/1	_____	0s	27ms/step
1/1	_____	0s	23ms/step
1/1	_____	0s	34ms/step
1/1	_____	0s	33ms/step
1/1	_____	0s	27ms/step
1/1	_____	0s	24ms/step
1/1	_____	0s	23ms/step
1/1	_____	0s	23ms/step
1/1	_____	0s	26ms/step
1/1	_____	0s	24ms/step
1/1	_____	0s	23ms/step
1/1	_____	0s	26ms/step
1/1	_____	0s	27ms/step
1/1	_____	0s	29ms/step
1/1	_____	0s	28ms/step
1/1	_____	0s	25ms/step
1/1	_____	0s	26ms/step
1/1	_____	0s	26ms/step
1/1	_____	0s	25ms/step
1/1	_____	0s	24ms/step
1/1	_____	0s	23ms/step
1/1	_____	0s	32ms/step

1/1	_____	0s	38ms/step
1/1	_____	0s	30ms/step
1/1	_____	0s	23ms/step
1/1	_____	0s	22ms/step
1/1	_____	0s	26ms/step
1/1	_____	0s	24ms/step
1/1	_____	0s	24ms/step
1/1	_____	0s	24ms/step
1/1	_____	0s	27ms/step
1/1	_____	0s	25ms/step
1/1	_____	0s	24ms/step
1/1	_____	0s	29ms/step
1/1	_____	0s	26ms/step
1/1	_____	0s	24ms/step
1/1	_____	0s	27ms/step
1/1	_____	0s	25ms/step
1/1	_____	0s	27ms/step
1/1	_____	0s	27ms/step
1/1	_____	0s	25ms/step
1/1	_____	0s	30ms/step
1/1	_____	0s	29ms/step
1/1	_____	0s	32ms/step
1/1	_____	0s	29ms/step
1/1	_____	0s	24ms/step
1/1	_____	0s	25ms/step
1/1	_____	0s	26ms/step
1/1	_____	0s	28ms/step
1/1	_____	0s	26ms/step
1/1	_____	0s	28ms/step
1/1	_____	0s	23ms/step
1/1	_____	0s	38ms/step
1/1	_____	0s	31ms/step
1/1	_____	0s	24ms/step
1/1	_____	0s	24ms/step
1/1	_____	0s	23ms/step
1/1	_____	0s	28ms/step
1/1	_____	0s	23ms/step
1/1	_____	0s	24ms/step
1/1	_____	0s	45ms/step
1/1	_____	0s	33ms/step
1/1	_____	0s	46ms/step
1/1	_____	0s	46ms/step
1/1	_____	0s	31ms/step
1/1	_____	0s	32ms/step
1/1	_____	0s	32ms/step
1/1	_____	0s	42ms/step
1/1	_____	0s	31ms/step
1/1	_____	0s	31ms/step
1/1	_____	0s	35ms/step

1/1	_____	0s	38ms/step
1/1	_____	0s	38ms/step
1/1	_____	0s	38ms/step
1/1	_____	0s	38ms/step
1/1	_____	0s	42ms/step
1/1	_____	0s	44ms/step
1/1	_____	0s	43ms/step
1/1	_____	0s	53ms/step
1/1	_____	0s	35ms/step
1/1	_____	0s	36ms/step
1/1	_____	0s	35ms/step
1/1	_____	0s	34ms/step
1/1	_____	0s	36ms/step
1/1	_____	0s	41ms/step
1/1	_____	0s	37ms/step
1/1	_____	0s	32ms/step
1/1	_____	0s	24ms/step
1/1	_____	0s	25ms/step
1/1	_____	0s	24ms/step
1/1	_____	0s	29ms/step
1/1	_____	0s	26ms/step
1/1	_____	0s	25ms/step
1/1	_____	0s	24ms/step
1/1	_____	0s	24ms/step
1/1	_____	0s	25ms/step
1/1	_____	0s	26ms/step
1/1	_____	0s	21ms/step
1/1	_____	0s	24ms/step
1/1	_____	0s	22ms/step
1/1	_____	0s	22ms/step
1/1	_____	0s	22ms/step
1/1	_____	0s	22ms/step
1/1	_____	0s	21ms/step
1/1	_____	0s	26ms/step
1/1	_____	0s	22ms/step
1/1	_____	0s	24ms/step
1/1	_____	0s	25ms/step
1/1	_____	0s	21ms/step
1/1	_____	0s	30ms/step
1/1	_____	0s	23ms/step
1/1	_____	0s	23ms/step
1/1	_____	0s	23ms/step
1/1	_____	0s	22ms/step
1/1	_____	0s	22ms/step
1/1	_____	0s	36ms/step
1/1	_____	0s	21ms/step
1/1	_____	0s	26ms/step

1/1	_____	0s	22ms/step
1/1	_____	0s	21ms/step
1/1	_____	0s	22ms/step
1/1	_____	0s	22ms/step
1/1	_____	0s	26ms/step
1/1	_____	0s	24ms/step
1/1	_____	0s	23ms/step
1/1	_____	0s	22ms/step
1/1	_____	0s	21ms/step
1/1	_____	0s	27ms/step
1/1	_____	0s	26ms/step
1/1	_____	0s	30ms/step
1/1	_____	0s	23ms/step
1/1	_____	0s	35ms/step
1/1	_____	0s	26ms/step
1/1	_____	0s	26ms/step
1/1	_____	0s	30ms/step
1/1	_____	0s	24ms/step
1/1	_____	0s	24ms/step
1/1	_____	0s	28ms/step
1/1	_____	0s	31ms/step
1/1	_____	0s	28ms/step
1/1	_____	0s	26ms/step
1/1	_____	0s	29ms/step
1/1	_____	0s	23ms/step
1/1	_____	0s	26ms/step
1/1	_____	0s	26ms/step
1/1	_____	0s	26ms/step
1/1	_____	0s	27ms/step
1/1	_____	0s	25ms/step
1/1	_____	0s	32ms/step
1/1	_____	0s	31ms/step
1/1	_____	0s	25ms/step
1/1	_____	0s	26ms/step
1/1	_____	0s	31ms/step
1/1	_____	0s	24ms/step
1/1	_____	0s	23ms/step
1/1	_____	0s	23ms/step
1/1	_____	0s	26ms/step
1/1	_____	0s	25ms/step
1/1	_____	0s	26ms/step
1/1	_____	0s	31ms/step
1/1	_____	0s	26ms/step
1/1	_____	0s	24ms/step
1/1	_____	0s	25ms/step
1/1	_____	0s	26ms/step
1/1	_____	0s	24ms/step
1/1	_____	0s	23ms/step
1/1	_____	0s	26ms/step


1/1	_____	0s 22ms/step
1/1	_____	0s 29ms/step
1/1	_____	0s 35ms/step
1/1	_____	0s 25ms/step
1/1	_____	0s 29ms/step
1/1	_____	0s 25ms/step
1/1	_____	0s 30ms/step
1/1	_____	0s 26ms/step
1/1	_____	0s 25ms/step
1/1	_____	0s 27ms/step
1/1	_____	0s 23ms/step
1/1	_____	0s 23ms/step
1/1	_____	0s 34ms/step
1/1	_____	0s 26ms/step
1/1	_____	0s 25ms/step
1/1	_____	0s 25ms/step
1/1	_____	0s 24ms/step
1/1	_____	0s 25ms/step
1/1	_____	0s 25ms/step
1/1	_____	0s 24ms/step
1/1	_____	0s 24ms/step
1/1	_____	0s 24ms/step
1/1	_____	0s 42ms/step
1/1	_____	0s 39ms/step
1/1	_____	0s 29ms/step
1/1	_____	0s 33ms/step
1/1	_____	0s 44ms/step
1/1	_____	0s 34ms/step
1/1	_____	0s 78ms/step
1/1	_____	0s 133ms/step
1/1	_____	0s 74ms/step
1/1	_____	0s 172ms/step
1/1	_____	0s 109ms/step
1/1	_____	0s 102ms/step
1/1	_____	0s 152ms/step
1/1	_____	0s 112ms/step
1/1	_____	0s 139ms/step
1/1	_____	0s 94ms/step
1/1	_____	0s 49ms/step
1/1	_____	0s 45ms/step
1/1	_____	0s 41ms/step
1/1	_____	0s 41ms/step
1/1	_____	0s 44ms/step
1/1	_____	0s 54ms/step
1/1	_____	0s 55ms/step
1/1	_____	0s 36ms/step
1/1	_____	0s 38ms/step
1/1	_____	0s 47ms/step
1/1	_____	0s 60ms/step

1/1	_____	0s	55ms/step
1/1	_____	0s	25ms/step
1/1	_____	0s	22ms/step
1/1	_____	0s	28ms/step
1/1	_____	0s	23ms/step
1/1	_____	0s	22ms/step
1/1	_____	0s	23ms/step
1/1	_____	0s	23ms/step
1/1	_____	0s	22ms/step
1/1	_____	0s	24ms/step
1/1	_____	0s	24ms/step
1/1	_____	0s	27ms/step
1/1	_____	0s	29ms/step
1/1	_____	0s	27ms/step
1/1	_____	0s	31ms/step
1/1	_____	0s	30ms/step
1/1	_____	0s	24ms/step
1/1	_____	0s	25ms/step
1/1	_____	0s	24ms/step
1/1	_____	0s	25ms/step
1/1	_____	0s	25ms/step
1/1	_____	0s	24ms/step
1/1	_____	0s	27ms/step
1/1	_____	0s	36ms/step
1/1	_____	0s	37ms/step
1/1	_____	0s	28ms/step
1/1	_____	0s	26ms/step
1/1	_____	0s	28ms/step
1/1	_____	0s	25ms/step
1/1	_____	0s	26ms/step
1/1	_____	0s	24ms/step
1/1	_____	0s	26ms/step
1/1	_____	0s	24ms/step
1/1	_____	0s	26ms/step
1/1	_____	0s	28ms/step
1/1	_____	0s	24ms/step
1/1	_____	0s	28ms/step
1/1	_____	0s	27ms/step
1/1	_____	0s	27ms/step
1/1	_____	0s	26ms/step
1/1	_____	0s	26ms/step
1/1	_____	0s	24ms/step
1/1	_____	0s	27ms/step
1/1	_____	0s	26ms/step
1/1	_____	0s	29ms/step
1/1	_____	0s	25ms/step
1/1	_____	0s	22ms/step
1/1	_____	0s	23ms/step
1/1	_____	0s	29ms/step

1/1	_____	0s	25ms/step
1/1	_____	0s	33ms/step
1/1	_____	0s	51ms/step
1/1	_____	0s	38ms/step
1/1	_____	0s	38ms/step
1/1	_____	0s	41ms/step
1/1	_____	0s	97ms/step
1/1	_____	0s	51ms/step
1/1	_____	0s	51ms/step
1/1	_____	0s	50ms/step
1/1	_____	0s	44ms/step
1/1	_____	0s	108ms/step
1/1	_____	0s	108ms/step
1/1	_____	0s	126ms/step
1/1	_____	0s	85ms/step
1/1	_____	0s	309ms/step
1/1	_____	0s	82ms/step
1/1	_____	0s	83ms/step
1/1	_____	0s	104ms/step
1/1	_____	0s	38ms/step
1/1	_____	0s	83ms/step
1/1	_____	0s	39ms/step
1/1	_____	0s	92ms/step
1/1	_____	0s	97ms/step
1/1	_____	0s	90ms/step
1/1	_____	0s	52ms/step
1/1	_____	0s	46ms/step
1/1	_____	0s	47ms/step
1/1	_____	0s	40ms/step
1/1	_____	0s	55ms/step
1/1	_____	0s	24ms/step
1/1	_____	0s	22ms/step
1/1	_____	0s	23ms/step
1/1	_____	0s	37ms/step
1/1	_____	0s	24ms/step
1/1	_____	0s	27ms/step
1/1	_____	0s	27ms/step
1/1	_____	0s	26ms/step
1/1	_____	0s	32ms/step
1/1	_____	0s	28ms/step
1/1	_____	0s	25ms/step
1/1	_____	0s	25ms/step
1/1	_____	0s	25ms/step
1/1	_____	0s	24ms/step
1/1	_____	0s	24ms/step
1/1	_____	0s	22ms/step
1/1	_____	0s	21ms/step
1/1	_____	0s	25ms/step
1/1	_____	0s	24ms/step

1/1	_____	0s	31ms/step
1/1	_____	0s	23ms/step
1/1	_____	0s	22ms/step
1/1	_____	0s	22ms/step
1/1	_____	0s	24ms/step
1/1	_____	0s	21ms/step
1/1	_____	0s	31ms/step
1/1	_____	0s	21ms/step
1/1	_____	0s	23ms/step
1/1	_____	0s	31ms/step
1/1	_____	0s	29ms/step
1/1	_____	0s	44ms/step
1/1	_____	0s	27ms/step
1/1	_____	0s	25ms/step
1/1	_____	0s	26ms/step
1/1	_____	0s	24ms/step
1/1	_____	0s	34ms/step
1/1	_____	0s	27ms/step
1/1	_____	0s	22ms/step
1/1	_____	0s	24ms/step
1/1	_____	0s	21ms/step
1/1	_____	0s	26ms/step
1/1	_____	0s	24ms/step
1/1	_____	0s	23ms/step
1/1	_____	0s	22ms/step
1/1	_____	0s	24ms/step
1/1	_____	0s	22ms/step
1/1	_____	0s	21ms/step
1/1	_____	0s	22ms/step
1/1	_____	0s	20ms/step
1/1	_____	0s	21ms/step
1/1	_____	0s	21ms/step
1/1	_____	0s	25ms/step
1/1	_____	0s	25ms/step
1/1	_____	0s	25ms/step
1/1	_____	0s	23ms/step
1/1	_____	0s	26ms/step
1/1	_____	0s	23ms/step
1/1	_____	0s	22ms/step
1/1	_____	0s	25ms/step
1/1	_____	0s	21ms/step
1/1	_____	0s	23ms/step
1/1	_____	0s	23ms/step
1/1	_____	0s	31ms/step
1/1	_____	0s	31ms/step
1/1	_____	0s	23ms/step
1/1	_____	0s	30ms/step
1/1	_____	0s	26ms/step
1/1	_____	0s	27ms/step

```
1/1 _____ 0s 26ms/step
1/1 _____ 0s 28ms/step
1/1 _____ 0s 27ms/step
1/1 _____ 0s 25ms/step
1/1 _____ 0s 32ms/step
```



Otimizar previsão

Criar dataset de treinamento

Inclui os mesmos passos realizados pela função `janelamento_lotes`, sem o embaralhamento de janelas.

```
# Serie de previsão
serie_forecast = serie[tam_trein - tam_janela:-1]

# Cria um dataset TF a partir dos valores da serie
dataset = tf.data.Dataset.from_tensor_slices(serie_forecast)

# Janelamento dos dados
dataset = dataset.window(tam_janela, shift=1, drop_remainder=True)

# Ajustar as janelas (flatten) colocando seus elementos em lotes
dataset = dataset.flat_map(lambda window: window.batch(tam_janela))
```

```
# Criar lotes de treinamento
dataset = dataset.batch(tam_lote).prefetch(1)
```

Previsão do conjunto de validação

Diferentemente do loop utilizado na previsão do modelo preliminar que processa uma janela por vez na previsão de cada lote, a função de previsão do modelo é invocada recebendo todo o dataset. A paralelização de lotes é realizada automaticamente pelo tensorflow.*


```
forecast = modelo_RNN.predict(dataset)

15/15 ————— 0s 8ms/step
```

Visualizar a previsão

```
# Ajustar formato
previsao = forecast.squeeze()

# Plotar resultados
plotar_series(tempo_valid, (x_valid, previsao))
```



Calcular MAPE

```
# Calcular MAPE
mape = tf.keras.metrics.MeanAbsolutePercentageError()
```

```
mape = tf.keras.metrics.mse =  
tf.keras.metrics.MeanAbsolutePercentageError()  
mape.update_state(x_valid, previsao)
```

```
MAPE = mape.result().numpy()/100  
print(MAPE)
```

```
0.19200124740600585
```

TDE02 - Comparar desempenho de modelos

Utilizar a série sintética para comparar o modelo RNN com os modelo Baseline, AUTOARIMA, GB e RN.

- Calcular e imprimir métricas do modelo ST_RNN
- Salvar as métricas no arquivo Métricas_Previsão.csv onde estão salvas as métricas de todos os modelos estudados até agora
- Plotar a métrica MAPE para os modelos: ST_Baseline, ST_AUTOARIMA, STGB, ST_RN, ST_RNN

Para realizar os passos anteriores você pode consultar o código fornecido nas avaliações formativas. Não é necessário refazer os códigos de outros modelos porque nas avaliações formativas as métricas de desempenho foram salvas no arquivo Métricas_Previsão.csv.

Calcular e imprimir métricas do modelo ST_RNN (valor 0,4)

```
metricas_st_rnn = metricas(previsao, x_valid)  
print("Métricas do modelo ST_RNN:")  
for metrica, valor in metricas_st_rnn.items():  
    print(f"{metrica}: {valor}")  
  
metricas_df = pd.DataFrame({'Modelo': ['ST_RNN'],  
                           'ME': [metricas_st_rnn['ME']],  
                           'MSE': [metricas_st_rnn['MSE']],  
                           'RMSE': [metricas_st_rnn['RMSE']],  
                           'MAE': [metricas_st_rnn['MAE']],  
                           'MPE': [metricas_st_rnn['MPE']],  
                           'MAPE': [metricas_st_rnn['MAPE']],  
                           'MIN-MAX': [metricas_st_rnn['MIN-MAX']]})  
  
try:  
    metricas_anteriores = pd.read_csv('Métricas_Previsão.csv')  
    metricas_df = pd.concat([metricas_anteriores, metricas_df],  
                           ignore_index=True)  
except FileNotFoundError:
```


pass

```
metricas_df.to_csv('Métricas_Previsão.csv', index=False)
```

```
Métricas do modelo ST_RNN:  
ME: -24.150157928466797  
MSE: 735.4100952148438  
RMSE: 27.118446350097656  
MAE: 24.289058685302734  
MPE: -0.190353661775589  
MAPE: 0.19200123846530914  
MIN-MAX: 0.19195806980133057
```

Salvar métricas para comparação (valor 0,4)

```
try:  
    dfMetricas = pd.read_csv('Métricas_Previsão.csv')  
except FileNotFoundError:  
    dfMetricas = pd.DataFrame()  
  
if 'ST_RNN' not in dfMetricas.columns:  
    dfMetricas['ST_RNN'] = None  
  
dfMetricas.to_csv('Métricas_Previsão.csv', index=False)
```

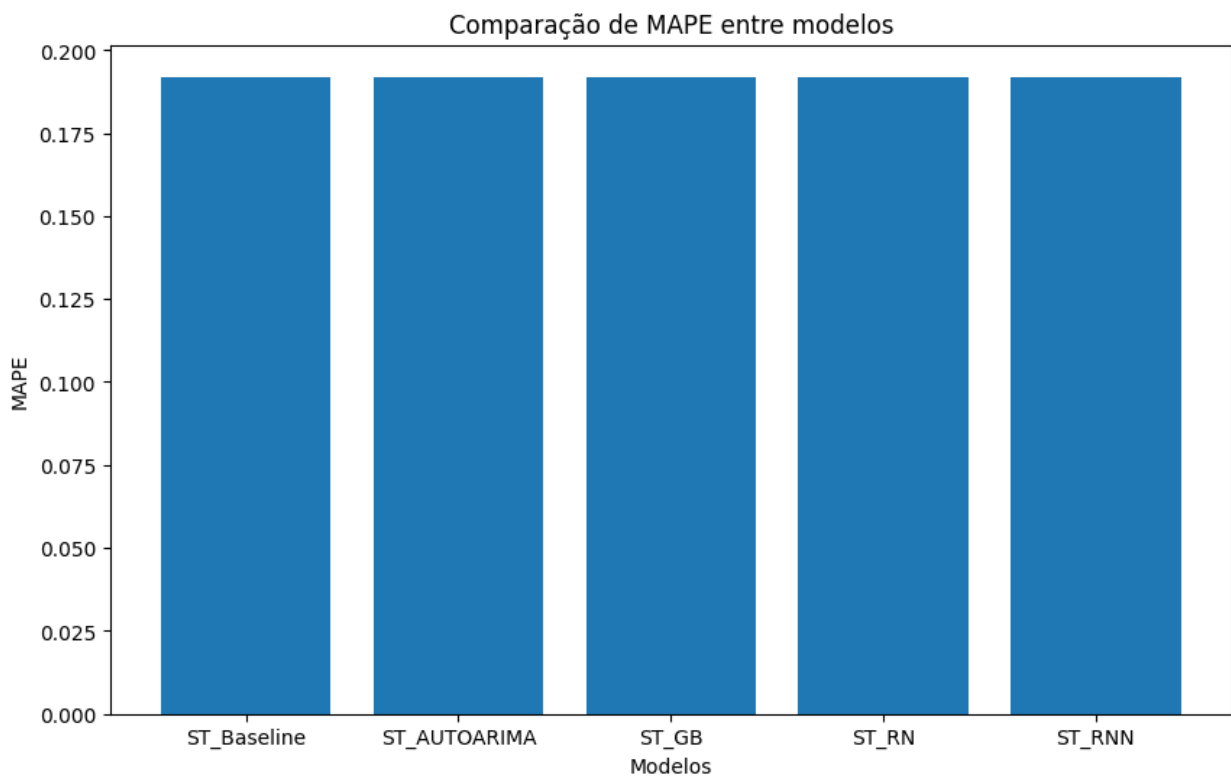
Plotar a métrica MAPE (valor 0,4)

Modelos: ST_Baseline, ST_AUTOARIMA, ST_GB, ST_RN, ST_RNN

```
try:  
    dfMetricas = pd.read_csv('Métricas_Previsão.csv')  
except FileNotFoundError:  
    print("Arquivo 'Métricas_Previsão.csv' não encontrado.")  
    dfMetricas = pd.DataFrame()  
  
if 'Modelo' in dfMetricas.columns and 'MAPE' in dfMetricas.columns:  
    modelos = ['ST_Baseline', 'ST_AUTOARIMA', 'ST_GB', 'ST_RN',  
               'ST_RNN']  
    mape_values = []  
    for modelo in modelos:  
        if modelo in dfMetricas['Modelo'].values:  
            mape = dfMetricas.loc[dfMetricas['Modelo'] == modelo,  
                                  'MAPE'].values[0]  
            mape_values.append(mape)  
        else:  
            print(f"Modelo {modelo} não encontrado no arquivo  
'Métricas_Previsão.csv'.")
```

```
plt.figure(figsize=(10, 6))
plt.bar(modelos, mape_values)
plt.xlabel('Modelos')
plt.ylabel('MAPE')
plt.title('Comparação de MAPE entre modelos')
plt.show()
else:
    print("Colunas 'Modelo' ou 'MAPE' não encontradas no arquivo 'Métricas_Previsão.csv'.")
```

Modelo ST_Baseline não encontrado no arquivo 'Métricas_Previsão.csv'.
 Modelo ST_AUTOARIMA não encontrado no arquivo 'Métricas_Previsão.csv'.
 Modelo ST_GB não encontrado no arquivo 'Métricas_Previsão.csv'.
 Modelo ST_RN não encontrado no arquivo 'Métricas_Previsão.csv'.



Conclusão (valor 0,8)

Colocar na célula abaixo a sua conclusão a respeito dos modelos de previsão de séries temporais estudados

- Baseline
- ARIMA

- Gradiente Boosting
- Redes Neurais
- Redes Neurais Recorrentes

Conclusão: ARIMA e Gradient Boosting mostraram bons resultados para capturar padrões estacionários e complexos, respectivamente. No entanto, dependem da preparação dos dados e da interpretação correta dos parâmetros. Redes Neurais e RNNs se destacam em capturar relações não lineares e dinâmicas, especialmente em séries com padrões complexos. Porém, podem ser mais desafiadores de treinar e otimizar, além de demandar maior poder computacional. A escolha do modelo ideal depende de fatores como a complexidade da série temporal, a disponibilidade de dados, a necessidade de interpretabilidade e os recursos computacionais disponíveis.

Considerando os resultados do presente trabalho, pode-se observar que o modelo RNN, apesar de demandar maior poder computacional, tende a ter um desempenho superior aos demais modelos, principalmente em séries temporais mais complexas, obtendo menor MAPE. Isso é devido à sua capacidade de capturar dependências ao longo do tempo e aprender representações complexas dos dados.

Recomenda-se considerar RNNs como uma boa opção para previsão de séries temporais em cenários complexos, porém, é crucial avaliar a complexidade do problema, requisitos de tempo de processamento e recursos computacionais disponíveis antes de implementar o modelo.